

CTI: Plataforma Analítica de Planejamento Financeiro

Entrega 1: Projeto Interdisciplinar Ciência de Dados

Identificação, coleta, exploração e preparação dos dados

Identificação	
Grupo	6
Professor orientador	Eduardo Savino Gomes
Integrantes	Gustavo Pires, Lúcio Vecchio, Luiz Henrique, Eric Aloise
Repositório	github.com/2026-2-NCC4/Projeto6

1. Introdução

A CTI Global cedeu ao projeto uma base com a projeção financeira de uma concessionária de infraestrutura. O objetivo desta primeira entrega é transformar esse arquivo bruto numa base analítica confiável e documentada, que sirva de ponto de partida comum para as análises estatísticas, os indicadores financeiros e o painel que o grupo vai construir.

O trabalho segue o CRISP-DM, a metodologia adotada pela disciplina. Esta entrega cobre duas de suas fases: Entender os Dados e Preparação dos Dados. Cada tarefa pedida no enunciado corresponde a uma seção deste relatório e a um artefato executável no repositório.

Tarefa do enunciado	Seção	Onde está no repositório
Identificar fontes de dados	2	Este relatório
Coletar dados iniciais	3	src/notebooks/01_perfil.ipynb e src/prepara.py
Descrever os dados	4	Notebook 01 e dicionário de dados
Explorar os dados	5 e 6	Notebook 01
Selecionar os dados	7	Notebook 02 e src/prepara.py
Limpar e uniformizar os dados	8	Notebook 02 e src/prepara.py
Derivar e integrar os dados	9	Notebook 02 e src/prepara.py
Formatar os dados	10	Notebook 02, src/prepara.py e dicionário de dados

2. Identificação das fontes de dados

O projeto usa uma única fonte de dados, fornecida pela empresa parceira.

Atributo	Descrição
Fonte	Arquivo Demonstrativo Fecap v3.csv, fornecido pela CTI Global
Natureza	Projeção financeira de uma concessionária de infraestrutura. São dados projetados, e não históricos
Responsável	CTI Global, que produziu e cedeu a base. A cópia de trabalho fica com o grupo, fora do repositório
Recebimento	21 de agosto de 2026, disponibilizado à turma
Versão e atualização	Versão v3 do arquivo, recebida uma única vez. Uma nova versão exigiria refazer a preparação
Formato e volume	CSV com 75.085.191 bytes e 1.002.000 linhas
Período	12 anos de horizonte. Pela convenção indicada pela CTI, o Ano 1 corresponde a 2027 e o Ano 12 a 2038
Cenários	1.200, gerados por simulação de Monte Carlo. Cada um é um futuro possível para a mesma concessão

Atributo	Descrição
Granularidade	Uma linha por cenário, ano e conta contábil, mais três linhas sem nome de conta por cenário e ano (seção 6)
Campos	ano, cenário, conta e valor
Condições de uso	Uso acadêmico e confidencial. O arquivo não é publicado e fica fora do repositório público
Limitações conhecidas	Sem cabeçalho; sem documentação das premissas da simulação; EBITDA sem memória de cálculo; último ano com contas a menos, por ser o encerramento da concessão

Como fontes de contexto, e não de dados, foram usadas as orientações enviadas pela CTI à turma em 8 de setembro de 2026, que explicam a natureza da base, e o material das disciplinas de Ciência de Dados e de Contabilidade e Finanças.

Fonte complementar: o IPCA foi considerado para converter valores nominais em valores reais, mas não foi integrado. A CTI não informou se a projeção já está ajustada pela inflação, e aplicar um ajuste sem essa resposta poderia distorcer os números em vez de corrigi-los.

3. Coleta dos dados iniciais

O arquivo foi guardado em `src/data/raw`, pasta excluída do controle de versão por regra no `.gitignore`, porque o repositório é público. Ele é aberto apenas para leitura.

O arquivo não segue o formato que as bibliotecas assumem por padrão. A leitura exigiu seis parâmetros, cada um corrigindo uma diferença específica:

Parâmetro	Valor	Motivo
Separador	ponto e vírgula	As colunas não são separadas por vírgula
Cabeçalho	nenhum	A primeira linha já é dado; sem essa indicação, um registro seria perdido
Nomes das colunas	ano, cenário, conta, valor	Definidos pelo grupo, já que o arquivo não traz
Codificação	latin-1	Com a codificação padrão, os acentos dos nomes das contas saem corrompidos
Separador decimal	vírgula	Formato numérico brasileiro
Separador de milhar	ponto	Sem ele, um valor como 1.234 seria lido como 1,234, mil vezes menor

Duas garantias acompanham a coleta. Cada linha recebe o número da linha correspondente no arquivo original, o que permite rastrear qualquer valor preparado até a fonte. E o script calcula a impressão digital SHA-256 do arquivo antes e depois da preparação: sendo iguais, fica provado que a preparação não alterou a base da CTI.

A coleta pode ser reproduzida de três formas: pelo notebook 01, pelo script `src/prepara.py` ou pelo notebook 02. Os dois notebooks têm uma célula de configuração para o Google Colab, que clona o repositório e copia a base a partir do Google Drive de quem executa, sem publicá-la. Para não expor a base, os notebooks mostram estrutura, contagens e resultados agregados, e nunca linhas individuais.

4. Descrição dos dados

Característica	Resultado
Registros	1.002.000 linhas
Dimensões	12 anos x 1.200 cenários = 14.400 combinações de ano e cenário
Contas contábeis	69, divididas em três blocos
BAL: balanço patrimonial	43 contas. Posições no fim de cada ano, como ativo, passivo e patrimônio líquido
DRE: demonstração do resultado	14 contas. Receita, custos, EBITDA e resultado do ano
FLU: fluxo de caixa	12 contas. Entradas, saídas, geração de caixa e saldos
Linhas sem nome de conta	43.200, exatamente três por combinação de ano e cenário
Cobertura por ano	69 contas nos anos 3 a 11; 68 nos anos 1 e 2; 42 no Ano 12

A base segue uma convenção de sinais que precisa ser respeitada em qualquer cálculo. No balanço, o ativo é positivo e o passivo total e o patrimônio líquido são negativos, em regra. Na DRE e no fluxo de caixa, entradas são positivas e saídas, como custos, tributos e distribuição aos acionistas, são negativas. Um valor negativo, portanto, não é erro. Há exceções, e o dicionário de dados registra o sinal observado de cada conta: as contas redutoras do ativo, como a depreciação acumulada, são negativas; o passivo circulante é positivo em cerca de 62% dos registros; e, no encerramento, os totais do balanço chegam a inverter de sinal.

O significado, o tipo, a unidade e a cobertura de cada um dos 81 campos da base analítica (3 de identificação, 69 contas e 9 derivados), além do grupo contábil, do tipo de linha e do sinal observado de cada conta, estão no dicionário de dados, publicado na mesma pasta deste relatório.

5. Exploração dos dados

5.1 Receita ao longo do horizonte




Figura 1: receita projetada por ano. Linha: mediana dos 1.200 cenários. Faixa: entre os percentis 10 e 90.

A receita mediana cai de R\$ 6,67 bilhões em 2027 para R\$ 6,09 bilhões em 2028 e depois cresce de forma contínua até R\$ 9,70 bilhões em 2037. Em 2038 ela salta 23%, para R\$ 11,93 bilhões. A CTI confirmou que o último ano é o encerramento da concessão, com a liquidação de direitos e obrigações, o que ajuda a entender por que ele se comporta diferente dos demais.

A faixa entre os cenários é estreita: o coeficiente de variação da receita vai de 0,53% em 2027 a 2,94% em 2037, e os cenários quase não divergem sobre a receita. O coeficiente cresce de 2027 a 2037 e recua em 2038, mas a largura da faixa entre os percentis 10 e 90 não: ela se estreita de 2027 a 2031, de R\$ 66 milhões para R\$ 7 milhões, e só depois se alarga.

5.2 Distribuição do resultado líquido




Figura 2: distribuição do resultado líquido em 2037 entre os 1.200 cenários.

Em 2037, o resultado líquido tem mediana de R\$ 4,67 bilhões e varia entre R\$ 3,27 e R\$ 5,83 bilhões. Nenhum cenário registra prejuízo em nenhum ano: os 14.400 resultados de cenário e ano são positivos, sem valores iguais a zero. A barra isolada perto de R\$ 4,41 bilhões é formada por cenários repetidos, tratados na seção 6.

5.3 Margens e geração de caixa

Ano	Margem EBITDA	Margem operacional	Margem líquida
2027	77,1%	63,6%	36,4%
2030	79,4%	60,2%	35,7%
2033	81,1%	64,0%	41,1%
2036	82,3%	67,9%	45,3%
2037	82,4%	71,2%	48,1%
2038	95,6%	73,8%	57,9%

A tabela mostra a mediana das margens entre os cenários. A margem EBITDA fica entre 75,8% e 82,4% até 2037. A margem líquida vai de 36,4% em 2027 a 48,1% em 2037, com o menor valor em 2028, de 32,6%.

A geração de caixa tem coeficiente de variação muito maior que o da receita: de 9% a 193% conforme o ano, contra menos de 3%. A comparação por esse coeficiente, porém, engana. A média da geração de caixa é pequena e muda de sinal entre os anos; em 2032 ela fica perto de zero, e é isso que leva o coeficiente a 193%. Em valor absoluto, a dispersão das duas variáveis é da mesma ordem:

Ano	Desvio da receita	Média da geração de caixa	Desvio da geração de caixa	Coeficiente de variação da geração de caixa
2027	35	343	183	53%
2030	73	-624	64	10%
2032	114	-22	42	193%
2034	170	880	167	19%
2037	285	793	169	21%
2038	330	-2.351	1.020	43%

Valores em R\$ milhões, entre os 1.200 cenários, com desvio padrão amostral; o coeficiente usa o valor absoluto da média. Até 2037, o desvio da geração de caixa fica entre R\$ 42 e R\$ 225 milhões e o da receita entre R\$ 35 e R\$ 285 milhões; o do caixa é menor em 7 dos 12 anos. No encerramento, o desvio da geração de caixa sobe para cerca de R\$ 1 bilhão. Por isso, o coeficiente de variação sozinho não indica onde está a incerteza da simulação, e as próximas análises comparam a dispersão também em valor absoluto.

6. Verificação da qualidade

Antes de preparar os dados, o grupo testou o que deveria ser verdade na base. Cada verificação declara uma expectativa e mostra o resultado; onde a expectativa falha, existe um achado.

Verificação	Resultado	Consequência
V1. Todo ano tem as mesmas contas	Anos 1 e 2 têm 68; o Ano 12 tem 42	O Ano 12 é o encerramento; contas ausentes não são zero
V2. Todos os grupos têm o mesmo tamanho	Três tamanhos: 42, 68 e 69 contas	O padrão vale para todos os cenários
V3. Cenário, ano e conta formam uma chave única	As únicas repetições estão nas linhas sem nome	Nenhuma conta financeira duplicada
V4. O balanço fecha	Ativo mais passivo fecha em zero nos 14.400 grupos, com resíduo máximo de centavos	Identidade dos totais conferida
V5. O que são as linhas sem nome	A primeira é o resíduo do balanço; as outras duas são sempre zero	São conferência do modelo, não contas
V6. O fluxo de caixa fecha	Saldo final igual a saldo inicial mais geração de caixa, nos 14.400 grupos	Serve de regra de conferência
V7. Todos os cenários são diferentes	94 cenários têm trajetória idêntica; restam 1.107 distintos	As 93 cópias alteram os percentis e precisam ser marcadas

A verificação V4 passou por uma correção durante o trabalho. A primeira versão subtraía o passivo do ativo e concluía que o balanço não fechava por bilhões. Na revisão, o grupo identificou que a base grava o passivo com sinal negativo; com a identidade escrita como soma, o balanço fecha em todos os grupos. O notebook registra o erro anterior em vez de apagá-lo.

Na V7, a comparação usa os valores completos, sem arredondamento, e cada grupo é conferido valor a valor. Os 94 cenários repetidos estão todos entre Cen_01001 e Cen_01200. O efeito aparece nos percentis: com todos os cenários, os percentis 5 e 10 do resultado líquido de 2037 são iguais, R\$ 4,41 bilhões; sem as cópias, passam a R\$ 4,46 e R\$ 4,60 bilhões.

7. Seleção dos dados

O que	Decisão	Justificativa
Contas contábeis	As 69 contas seguem para a base	Cada análise escolhe as suas; excluir agora limitaria as próximas entregas
Linhas sem nome de conta	Saem da base de contas, mas são preservadas num arquivo de auditoria	Não são contas financeiras (V5); apagá-las eliminaria a conferência do modelo
Cenários	Os 1.200 permanecem	A remoção das cópias depende de resposta da CTI; elas são marcadas, não excluídas
Anos	Os 12 anos permanecem, com o Ano 12 marcado	O encerramento é parte da concessão, mas precisa poder ser separado nas análises de tendência

8. Limpeza e uniformização

- Nomes das contas: 9 contas foram gravadas com dois espaços antes do hífen. Isso não cria contas duplicadas, mas faz o bloco BAL aparecer como dois blocos diferentes. Os espaços foram padronizados numa coluna nova, e o nome original foi mantido em outra.
- Campos de apoio: foram criados o número do ano (1 a 12), o ano pela convenção da CTI (2027 a 2038) e o bloco de cada conta (BAL, DRE ou FLU).
- Validação da chave: antes de reorganizar os dados, o script confirma que nenhuma combinação de cenário, ano e conta se repete. Se houvesse repetição, uma soma automática juntaria dois valores sem aviso. A trava foi testada inserindo uma duplicata de propósito, e a preparação foi interrompida como esperado.
- Valores ausentes: as contas que não existem no Ano 12 ficam vazias. Preenchê-las com zero afirmaria um valor que a CTI não informou.
- Contas de nome parecido: Emprést e Empréstimos, assim como Outros deb e Outros Débitos, não foram unidas. Estão em grupos diferentes do balanço e têm sinais diferentes.
- Sinais: nenhum valor negativo foi invertido. A convenção de sinais é parte do significado do dado.

9. Derivação e integração

Integração: os três demonstrativos, que no arquivo original estão em linhas separadas, foram reunidos numa única linha por cenário e ano. O resultado tem 14.400 linhas, uma para cada combinação dos 1.200 cenários com os 12 anos. Nenhuma fonte externa foi integrada, pelo motivo exposto na seção 2.

Derivação: nove colunas novas foram criadas, sem alterar nenhuma conta original.

Coluna	Descrição
encerramento	Indica o Ano 12, para que as análises de tendência possam separá-lo
residuo_balanco	Total do ativo mais total do passivo; deve ser próximo de zero
conferencia_modelo	A primeira linha sem nome de conta, trazida de volta para comparação
margem_ebitda	EBITDA dividido pela receita, com o EBITDA como fornecido pela CTI
margem_operacional	Resultado operacional dividido pela receita
margem_liquida	Resultado líquido dividido pela receita
grupo_repeticao	Grupo dos cenários com trajetória idêntica
cenario_repetido	Indica se o cenário pertence a um grupo de repetição
copia_excedente	Indica as cópias além da primeira; filtrar por ela permite analisar sem cópias

O EBITDA fornecido pela CTI foi mantido. Ele não coincide com o Resultado Operacional menos a D&A assinada, que é negativa na base; sua memória de cálculo ainda não foi informada pela CTI.

10. Formatação

Arquivo	Conteúdo	No repositório
base_analitica.parquet	Uma linha por cenário e ano: 14.400 linhas e 81 colunas	Não, por conter valores da CTI
base_longa.parquet	Uma linha por cenário, ano e conta, com o nome original preservado	Não
auditoria_sem_conta.parquet	As 43.200 linhas sem nome de conta	Não
relatorio_qualidade.json	Resultado das verificações e impressão digital da entrada	Não
dicionario_dados.csv	O dicionário de dados em CSV, para abrir em planilha	Não
dicionario_dados.md	Descrição de cada campo, sem valores	Sim

O formato Parquet foi escolhido por guardar os tipos de cada coluna e ser muito menor que o CSV. Os arquivos com valores ficam em src/data/processed, também excluída do controle de versão.

Toda a preparação é reproduzível com um único comando, `python src/prepara.py`, que roda em cerca de 5 segundos num computador pessoal e refaz 15 verificações a cada execução: conservação dos registros, cobertura dos 12 anos e as identidades do balanço, da DRE e do fluxo de caixa. Se alguma falhar, a execução é interrompida antes de gravar qualquer arquivo, e a base da última execução aprovada continua como estava. O notebook 02 executa as mesmas funções passo a passo, mostra o efeito de cada etapa e confirma que a base construída por ele é idêntica à do script e à relida do arquivo Parquet.

11. Limitações e pendências

- A memória de cálculo do EBITDA não foi informada pela CTI.
- O passivo circulante aparece com sinal positivo em cerca de 62% dos registros e não é igual à soma das contas do seu grupo. Isso precisa ser esclarecido antes do cálculo dos índices de liquidez.
- Não se sabe se os 94 cenários repetidos são intencionais. Enquanto isso, as análises devem declarar se usam todos os cenários ou só os distintos.
- Não se sabe se os valores estão ajustados pela inflação.
- A execução pelo Google Colab foi preparada nos dois notebooks, mas testada apenas no ambiente local.

12. Conclusão

A entrega transforma um arquivo de um milhão de linhas, sem cabeçalho e com particularidades de formato, numa base de 14.400 linhas verificada, documentada e reproduzível. As verificações mostraram que as identidades contábeis testadas fecham em todos os grupos comparáveis, identificaram os cenários repetidos e explicaram as linhas sem nome de conta; a composição do passivo circulante e a memória do EBITDA seguem pendentes. As decisões de preparação foram registradas com justificativa, e nenhuma delas alterou a fonte.

Essa base é o ponto de partida das próximas entregas. A Análise Inferencial vai usá-la para as medidas descritivas, histogramas e boxplots; Contabilidade e Finanças, para os demonstrativos e índices; e a Entrega 2, para a regressão e o painel. Partir do mesmo arquivo é o primeiro passo para que os números batam entre os documentos; o segundo é usar os mesmos filtros e fórmulas, o que o grupo confere antes de cada envio.

13. Referências

- FECAP. Projeto Interdisciplinar CTI: Plataforma Analítica de Planejamento Financeiro. Enunciado oficial, 4º CCOMP, 2026/2.
- CTI Global. Orientações sobre a natureza da base de dados e a simulação de cenários. Comunicação à turma, 08/09/2026.
- Material da disciplina Projeto Interdisciplinar Ciência de Dados: CRISP-DM (Aula 04) e preparação de dados com Python (Aula 05).
- Repositório do projeto: github.com/2026-2-NCC4/Projeto6. Notebooks 01_perfil e 02_preparacao, script `src/prepara.py` e dicionário de dados.