FinSight

Dados financeiros em perspectiva

Análise Inferencial de Dados

Regressão associativa, validação por trajetórias e diagnóstico

Identificação	Entrega 2
Grupo	6 - DevLeaders
Integrantes	Gustavo Pires; Lúcio Vecchio; Luiz Henrique Zaim da Cruz; Eric Aloise
Orientação	Rodnil da Silva Moreira Lisboa
Data de referência	08/11/2026
Versão do código	7af4c5209a97
Repositório	github.com/2026-2-NCC4/Projeto6

1. Problema e desenho

Associação contemporânea de receita, custos e ano com resultado líquido em projeções simuladas.

Fonte CTI v3: 1.002.000 linhas brutas, 1.200 cenários e 12 anos. A preparação E1 preserva a origem e gera 14.400 linhas por cenário/ano. A análise principal utiliza os Anos 1-11: 13.200 linhas e 1.107 trajetórias distintas.

Receita e custos são componentes parciais do resultado. O objetivo é descrever associação condicionada ao ano, sem reconstruir todas as parcelas da identidade contábil. Não se trata de previsão futura nem de estimativa causal.

Valores modelados em milhões de R$, convenção acadêmica. Ano 12 é encerramento e fica numa análise de sensibilidade. Saídas e figuras são agregadas, sem identificadores ou previsões individuais.

2. Particionamento e escolha

Conjunto	Linhas	Trajetórias
treino	7293	663
validacao	3465	222
teste	2442	222

GroupShuffleSplit, semente 20261105: aproximadamente 60/20/20 dos grupos. Todos os anos do cenário e todos os cenários com trajetória idêntica ficam no mesmo grupo. A interseção entre grupos de treino, validação e teste foi zero.

Modelo simples: intercepto e receita. Modelo múltiplo: intercepto, receita, custos assinados e dez indicadores de ano, com Ano 1 como referência. OLS ajustado somente no treino. Seleção pelo menor RMSE na validação; o teste não escolhe parâmetros. Covariância agrupada por trajetória.

Validação	MAE (milhões)	RMSE (milhões)	R^2
simples	78,2672	100,0118	0,9851
multipla	47,2072	69,7148	0,9928

3. Resultado no teste

Método	MAE (milhões)	RMSE (milhões)	R^2
Múltiplo	20,0627	33,6225	0,9984
Média por ano no treino	36,1714	83,5931	0,9899

O modelo reduz o RMSE em aproximadamente 59,8% frente à referência por ano. O R^2 elevado de ambos também reflete as tendências anuais comuns; não prova capacidade de prever anos ou operações não observados.

4. Coeficientes e interpretação

Termo	Coeficiente	IC 95% inferior	IC 95% superior
const	-1.424,9235	-1.658,1496	-1.191,6974
receita_milhoes	0,5929	0,5447	0,6412
custos_milhoes	0,0831	-0,0694	0,2355
ano_2	-99,5811	-124,9056	-74,2567
ano_3	-61,4310	-77,6170	-45,2449
ano_4	-23,5891	-39,9792	-7,1991
ano_5	100,7011	56,6095	144,7927
ano_6	174,7659	115,0126	234,5191
ano_7	123,3797	60,4837	186,2757
ano_8	92,9696	14,3449	171,5943
ano_9	95,0697	0,7070	189,4325
ano_10	232,2488	97,1864	367,3112
ano_11	409,3826	221,5001	597,2651

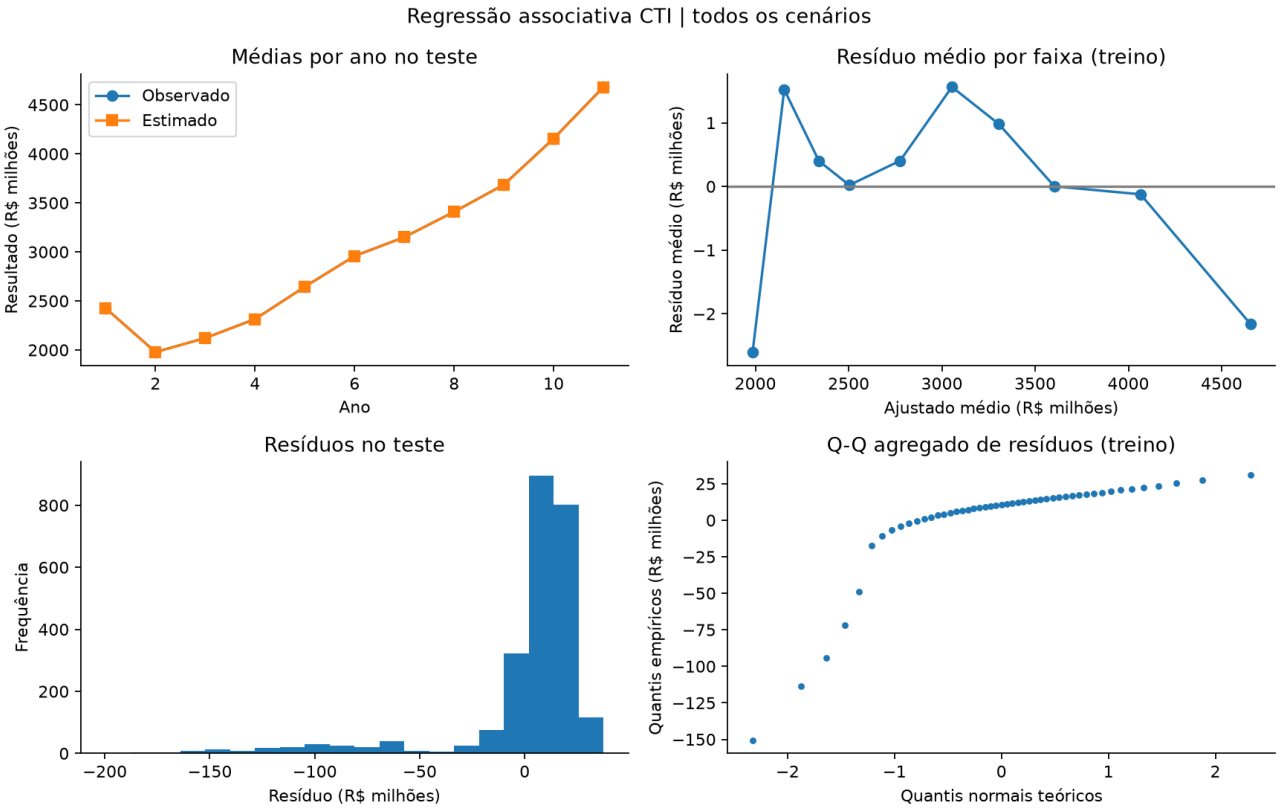
Receita: mantendo ano e custo constantes, mais R$ 1 milhão associa-se a cerca de R$ 0,593 milhão de resultado. O custo é assinado: aumentar a despesa em módulo reduz seu regressor. Seu IC inclui zero; isso não significa ausência de importância econômica, pois há forte colinearidade e condicionamento.

Os coeficientes de ano são diferenças em relação ao Ano 1. O intercepto não tem interpretação econômica isolada fora do domínio observado. Os intervalos agrupados não resolvem possível dependência entre cenários de um mesmo simulador.

Auditoria contábil: resultado líquido = receita + tributos + custos + depreciação/amortização + resultado financeiro + outros resultados operacionais + IR/CSLL. Resíduo máximo na base: cerca de R$0,0000505, arredondado a zero. O modelo usa só parte dessas parcelas.

Taxas agregadas de tributos e IR/CSLL: aproximadamente 8,45% e 34,37%. O produto (1-t)(1-ir) = 0,6008 é comparação descritiva, não demonstra que o coeficiente parcial 0,5929 seja repasse tributário. Taxas variáveis, variáveis omitidas e controles de ano impedem essa conclusão. O intervalo do custo inclui zero; omissão de parcelas é hipótese a investigar, não explicação comprovada.

5. Diagnósticos e limitações



Breusch-Pagan exploratório: LM 295,3821; p = 4.38e-56. A dependência em painel limita a calibração desse p-valor. Correlação defasada dos resíduos dentro de cenário: 0,9506.

VIF: receita 61,7290; custos 24,7763; máximo entre regressores 81.86. Colinearidade alta e dependência temporal tornam inadequada uma interpretação causal dos coeficientes.

As figuras revelam padrões de resíduos; não se pressupõe normalidade ou homocedasticidade. Médias por faixa e por ano podem ocultar extremos individuais. Os quantis Q-Q são agregados. Erros-padrão agrupados são usados no lugar dos iid.

6. Sensibilidade e reprodutibilidade

Recorte	RMSE de teste (milhões)	R² de teste
Anos 1-11	33,6225	0,9984
Sem cópias	33,6225	0,9984
Inclui Ano 12	36,2777	0,9993

As 93 cópias excedentes estão no grupo destinado à validação nesta semente. Retirá-las não altera treino nem teste, e o múltiplo segue escolhido; por isso as métricas finais são idênticas. Não generalizar essa igualdade a outras divisões.

Ao incluir Ano 12, o erro absoluto aumenta. Seu R² maior não implica melhoria: há outra escala de variabilidade e outro regime. Manter a análise principal em 1-11 evita misturar encerramento com operação.

Notebook E2_Regressao_CTI.ipynb: seis células de código executadas integralmente em kernel local limpo, sem erros. Não foi executado no Google Colab nesta etapa. O formato também é utilizável em Jupyter/Colab após instalar dependências e disponibilizar dados autorizados.

Reprodução: python -m src.cti.executar_e2 --csv <cópia autorizada>. Saídas em src/data/processed/e2, fora do Git. SHA-256 da origem: a93fb4555eab2eee7a437b98c2ff5cf4c392336d745a835b529974635cf8a3fc

Ambiente: {"python": "3.13.14", "pandas": "3.1.1", "numpy": "2.5.4", "scikit-learn": "1.9.1", "statsmodels": "0.15.0", "streamlit": "1.67.0"}

Referências: enunciado FINAL FECAP; src/prepara.py e planilha E1; scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html; statsmodels.org/stable/regression.html. Código e evidências agregadas estão nas pastas da E2.